

逐笔成交数据、因子选股与LSTM

数据处理、因子评价、换手控制回测与Walk-forward LSTM

量化交易项目报告

2026 年8 月3 日

摘要

该项目完成了从逐笔成交数据到日频与分钟频数据、因子构建与评价、执行约束组合回测，以及分钟级LSTM 预测的完整研究流程。样本包含300 只股票和302 个交易日。正式组合只使用截至上一交易日的历史信息，以Top30、每5 日调仓和Top60 持有缓冲降低换手；次日开盘口径在卖出手续费、双边滑点、平方根冲击、停牌和涨跌停限制全部生效后，完整样本累计收益为32.74%，年化收益为29.51%，最大回撤为-11.27%，夏普率为1.494。最后20% 留出期绝对收益为-2.61%，但同期等权基准为-7.61%，累计主动收益为5.41%。

目录

1	研究目标与总体流程	2
2	数据处理	3
2.1	读取、排序与基础校验	3
2.2	价格单位恢复与复权	3
2.3	OHLC 与买卖方向聚合	3
2.4	无成交时点的填充	3
3	因子构建与公式	4
3.1	横截面预处理	5
4	因子评价与图像解释	6
4.1	IC、Rank IC 与分组收益	6
4.2	相关性与多空净值	8
5	组合构建与无前视回测	10
5.1	Historical IC 加权形成综合信号	10
5.2	换手控制与持仓规则	10
5.3	成交时点、限制与交易成本	10
6	风险收益结果与稳健性检验	11
6.1	绩效指标定义	11
6.2	研究期与留出期	12
7	多股票Walk-forward LSTM	14
7.1	样本与特征	14
7.2	Expanding-window 验证	14
7.3	准确率与解释	14
8	结论	17

1 研究目标与总体流程

本项目围绕三个问题展开：第一，逐笔成交数据能否被无前视地加工成可复用的日频和分钟频数据；第二，七个横截面因子是否具有预测下一交易日收益的能力，并能否在真实交易约束下产生超额收益；第三，LSTM 是否能在严格的时间序列样本外验证中提供简单逻辑回归之外的分钟级排序信息。

该项目遵循以下步骤：

Step 1 逐笔成交清洗

Step 2 日频及分钟频聚合

Step 3 因子构建

Step 4 因子评价

Step 5 Historical IC 加权

Step 6 执行约束回测

Step 7 稳健性分析

Step 8 Walk-forward LSTM

报告把预测能力、执行成本和样本外表现分开评价。所有正式策略统计均来自非前视版本`historical_20d_ic`；使用同日未来收益的版本只用于展示数据泄漏，不计入正式结论。

2 数据处理

2.1 读取、排序与基础校验

逐笔文件首先按股票、交易日和成交时间排序，并检查价格、成交量、买卖方向和复权因子的类型与缺失情况。项目覆盖300只股票、302个交易日。分钟时间轴固定包含集合竞价、上午与下午连续竞价以及15:00收盘分钟，每日共253个时间点。

输出的11个基础字段为：开盘价、最高价、最低价、收盘价、成交量、成交笔数、成交额、主动买量、主动卖量、主动买额和主动卖额。价格字段形成日频宽表与逐日分钟宽表；最终另生成90,600行的日频K线长表，供因子与回测程序统一读取。

2.2 价格单位恢复与复权

原始成交价格以乘100的整数保存，因此先恢复真实成交价格：

$$P_{i,t}^{\text{real}} = \frac{P_{i,t}^{\text{raw}}}{100}. \quad (2.1)$$

随后对价格字段乘以当日复权因子 $F_{i,t}$ ：

$$P_{i,t}^{\text{adj}} = P_{i,t}^{\text{real}} \times F_{i,t}. \quad (2.2)$$

复权价格用于跨日收益和技术类因子，以消除分红、送股等公司行为造成的机械跳变。成交额仍按真实未复权价格计算：

$$A_{i,t} = P_{i,t}^{\text{real}} \times V_{i,t}, \quad (2.3)$$

因为成交额描述的是当时真实发生的交易金额，不应被复权因子改变。

2.3 OHLC 与买卖方向聚合

每个日频或分钟频分组内，第一笔成交价为开盘价，最大值为最高价，最小值为最低价，最后一笔成交价为收盘价；成交量、成交笔数和成交额采用求和。买卖方向按`BSflag`拆分：0为主动买、1为主动卖、2为集合竞价，由此分别汇总主动买卖的量和金额。

2.4 无成交时点的填充

价格只使用已经发生过的历史收盘价向后填充。日频缺失OHLC使用前一交易日收盘价，分钟频缺失OHLC使用前一分钟收盘价；在第一笔成交出现之前不使用当天未来成交价。没有成交的量、额和笔数统一填0。这一规则避免了把未来价格填回过去分钟的前视偏差。

3 因子构建与公式

令 A 为成交额, V 为成交量, N 为成交笔数, O, H, L, C 分别为复权后的开盘、最高、最低和收盘价; $BVol$ 与 $SVol$ 为主动买量与主动卖量, $r_t^{cc} = C_t/C_{t-1} - 1$ 。本项目使用以下七个因子。

i) 成交额多窗口均值离散度先计算成交额的多周期移动平均:

$$\bar{A}^{(w)}_{i,t} = \frac{1}{w} \sum_{j=0}^{w-1} A_{i,t-j}$$

$$w \subseteq 1, 5, 10, 20$$

因子定义为:

$$F_{i,t}^{Amount} = \log(1 + \text{sd}(\bar{A}^{(1)}, \bar{A}^{(5)}, \bar{A}^{(10)}, \bar{A}^{(20)}))$$

ii) 主动买卖不平衡冲击因子先计算当日主动买卖不平衡:

$$OI_{i,t} = \frac{BVol_{i,t} - SVol_{i,t}}{BVol_{i,t} + SVol_{i,t}}$$

因子定义为当日不平衡减去此前10个交易日的平均不平衡:

$$F_{i,t}^{Imbalance} = OI_{i,t} - \frac{1}{10} \sum_{j=1}^{10} OI_{i,t-j}$$

集合竞价成交不计入主动买入和卖出量。

iii) 10日日内振幅因子首先计算每日振幅:

$$\text{Range}_{i,t} = \frac{H_{i,t} - L_{i,t}}{C_{i,t}}$$

然后取最近10个交易日的平均值:

$$F_{i,t}^{\text{Range}} = \frac{1}{10} \sum_{j=0}^9 \text{Range}_{i,t-j}$$

iv) 5日反转因子先计算过去5个交易日的累计收益:

$$R_{i,t}^5 = \frac{C_{i,t}}{C_{i,t-5}} - 1$$

反转因子取其相反数:

$$F_{i,t}^{\text{Reversal}} = -(\frac{C_{i,t}}{C_{i,t-5}} - 1)$$

因子值越大, 说明股票过去5日表现越弱, 反转候选特征越明显。

v) 20日单笔成交规模异常因子首先计算平均每笔成交金额:

$$\text{ATS}_{i,t} = \frac{A_{i,t}}{\max(N_{i,t}, 1)}$$

进行对数变换:

$$X_{i,t} = \log(1 + \text{ATS}_{i,t})$$

计算20日均值:

$$\bar{X}_{i,t}^{20} = \frac{1}{20} \sum_{j=0}^{19} X_{i,t-j}$$

最终因子为20日滚动标准化结果:

$$F^{\text{TradeSize}}_{i,t} = \frac{X_{i,t} - \bar{X}_{i,t}^{20}}{s_{20}(X_{i,t}, X_{i,t-1}, \dots, X_{i,t-19})}$$

因子绝对值越大, 表示当日平均单笔成交规模相对于近期水平越异常。

vi) 10日价量压力因子首先计算日收益率:

$$r_{i,t} = \frac{C_{i,t}}{C_{i,t-1}} - 1$$

计算对数成交量变化:

$$\Delta v_{i,t} = \log(1 + V_{i,t}) - \log(1 + V_{i,t-1})$$

单日报量压力为:

$$\text{PVP}_{i,t} = r_{i,t} \Delta v_{i,t}$$

最终因子为最近10日的平均价量压力:

$$F^{\text{PriceVolume}}_{i,t} = \frac{1}{10} \sum_{j=0}^9 r_{i,t-j} \Delta v_{i,t-j}$$

正值表示价格与成交量变化方向一致, 负值表示价格与成交量变化方向相反。

vii) 5日隔夜-日内收益背离因子隔夜收益率定义为:

$$r_{i,t}^{\text{Overnight}} = \frac{O_{i,t}}{C_{i,t-1}} - 1$$

日内收益率定义为:

$$r_{i,t}^{\text{Intraday}} = \frac{C_{i,t}}{O_{i,t}} - 1$$

单日隔夜-日内背离为:

$$D_{i,t} = r_{i,t}^{\text{Overnight}} - r_{i,t}^{\text{Intraday}}$$

最终取最近5个交易日的平均值:

$$F^{\text{GapIntraday}}_{i,t} = \frac{1}{5} \sum_{j=0}^4 (r_{i,t-j}^{\text{Overnight}} - r_{i,t-j}^{\text{Intraday}})$$

以上均为原始时间序列因子, 进入因子评价和组合构建前, 程序会在每个交易日进行横截面winsorization, 以及standardization:

$$\tilde{F}_{i,t} = \min(\max(F_{i,t}, Q_{0.01,t}), Q_{0.99,t})$$

$$Z_{i,t} = \frac{\tilde{F}_{i,t} - \text{Mean}_i(\tilde{F}_{i,t})}{\text{Std}(\tilde{F}_{i,t})}$$

其中 $Q_{0.01,t}$ 和 $Q_{0.99,t}$ 分别是当日因子横截面的1%和99%分位数。

3.1 横截面预处理

每天对每个因子进行1% 和99% 分位做winsorization, 再做横截面standardization:

$$z_{i,t} = \frac{x_{i,t} - \bar{x}_t}{s_t}. \quad (3.1)$$

4 因子评价与图像解释

4.1 IC、Rank IC 与分组收益

评价目标为下一交易日收盘到收盘收益。普通IC 是当日因子与下一日收益的Pearson 相关系数；Rank IC 是这两个变量的Spearman 相关系数。报告同时计算均值、波动和ICIR：

$$\text{ICIR} = \frac{\overline{\text{IC}}}{\sigma(\text{IC})}. \quad (4.1)$$

五分组检验将每日股票按因子从低到高分为Q1-Q5，比较组间平均收益、累计净值与Q5-Q1 多空收益。若因子呈负向预测，则综合策略会根据historical IC 自动反转其方向。

表 4.1: 因子评价汇总

因子	IC	Rank IC	Rank ICIR	Q5-Q1 累计收益
成交额多窗口均值离散度	-0.0774	-0.1070	-11.711	-75.86%
5 日主动买卖不平衡	0.0016	-0.0017	-0.266	3.03%
10 日日内振幅	-0.0396	-0.0783	-6.871	-41.95%
5 日反转	0.0303	0.0558	6.357	50.53%
20 日单笔成交规模异常	-0.0225	-0.0500	-8.536	-36.25%
10 日价量压力	-0.0424	-0.0752	-10.354	-51.65%
5 日隔夜-日内收益背离	0.0324	0.0539	7.187	80.41%

每张图按同一方式阅读：左上为Q1-Q5 平均收益，用于检查单调性；右上为各分组累计净值；左下为Q5-Q1 多空净值；右下为滚动Rank IC，以观察因子有效性的时变特征。




图 4.1: 成交额多窗口均值离散度因子诊断。负Rank IC 和下降的分组收益说明该因子应反向使用。




图 4.2: 主动买卖不平衡因子诊断。其Rank IC 接近零，单因子预测力较弱，因此不应单独承担组合方向。




图 4.3: 10日日内振幅因子诊断。高振幅组未来收益较弱，表现为稳定的负向因子。




图 4.4: 5 日反转因子诊断。正Rank IC 与正多空收益表明近期弱势股票随后存在一定反弹。




图 4.5: 20 日单笔成交规模异常因子诊断。异常放大的平均单笔成交规模与下一日收益呈负相关。




图 4.6: 10 日价量压力因子诊断。该因子呈负向预测，显示近期价量同向压力可能伴随后续修正。




图 4.7: 5 日隔夜-日内收益背离因子诊断。其Q5-Q1 累计收益为80.41%，是新增因子中表现最强的一项。

4.2 相关性与多空净值

因子相关性用于识别重复信息。最大绝对相关性约为0.535，出现在隔夜-日内背离与5 日反转之间；其余组合并未达到完全共线。新增因子在组合中使用保守信号乘数，防止短样本中的强IC 直接主导权重。




图 4.8: 因子横截面相关系数热力图。




图 4.9: 因子Q5-Q1 多空累计净值。正负方向不同的因子在组合前按historical IC 调整方向。

5 组合构建与无前视回测

5.1 Historical IC 加权形成综合信号

因子 k 在交易日 t 的方向和权重只使用截至 $t - 1$ 的20 日historical IC:

$$\bar{IC}_{k,t} = \frac{1}{20} \sum_{s=t-20}^{t-1} IC_{k,s}, \quad w_{k,t} = \frac{\bar{IC}_{k,t}}{\sum_j |\bar{IC}_{j,t}|}. \quad (5.1)$$

综合得分为

$$Score_{i,t} = \sum_k w_{k,t} z_{i,k,t}. \quad (5.2)$$

这里不能使用 $IC_{k,t} = \text{corr}(F_{k,t}, R_{t+1})$ 直接决定 t 日交易, 因为 R_{t+1} 在下单时尚未发生。

5.2 换手控制与持仓规则

持仓30 只, 调仓频率为每5 个交易日, 已持有股票只要仍位于综合排名前60 就继续保留, 再从最新排名中补足30 只。缓冲区使排名第30 与第31 的微小变化不再自动触发交易。




图 5.1: 不同换手控制政策比较。次日开盘口径日均单边换手率为8.27%。

5.3 成交时点、限制与交易成本

信号在 t 日形成, 只能在 $t + 1$ 日开盘或收盘成交, 随后持有到下一对应价格时点。成交量或成交额为零视为停牌; 一字涨停不能买入, 一字跌停不能卖出; 无法卖出的股票继续保留。

成本由三部分组成: 卖出金额的5 个基点手续费; 买卖双方各5 个基点基础滑点; 以及订单金额占当日成交额比例驱动的平方根冲击:

$$c_{i,t}^{impact} = \min \left(c_{max}, \eta \sigma_{i,t} \sqrt{\frac{Q_{i,t}}{ADV_{i,t}}} \right). \quad (5.3)$$

其中 Q 为订单金额, ADV 为日成交额, σ 为波动尺度, η 为冲击系数。该设计使低流动性股票和大额订单承担更高成本。

6 风险收益结果与稳健性检验

6.1 绩效指标定义

累计收益为 $\prod_t(1+r_t)-1$ ；年化收益为 $(1+R)^{252/T}-1$ ；年化波动率为 $\sigma(r)\sqrt{252}$ ；最大回撤为净值相对历史峰值的最小跌幅；夏普率为年化平均超额于无风险利率后的收益除以年化波动；信息比率为主动收益均值除以跟踪误差并年化。等权基准使用入场日可以买入股票的当日等权收益。

表 6.1: 最终策略完整样本风险收益

指标	次日收盘	次日开盘
成本前累计收益	26.99%	42.63%
成本后累计收益	18.15%	32.74%
年化收益	16.45%	29.51%
年化超额收益	12.63%	25.70%
年化波动率	18.52%	18.45%
最大回撤	-16.98%	-11.27%
夏普率	0.915	1.494
信息比率	1.078	1.936
日均单边换手	8.37%	8.27%
总交易成本	871,169	893,843




图 6.1: 正式因子策略净值、等权基准与回撤。次日开盘结果在收益和回撤两方面优于次日收盘。




图 6.2: 收益、波动、回撤、夏普率、信息比率和换手率的并列比较。

6.2 研究期与留出期

为区分研究选择效应与时间外推能力，样本按时间切分为前80% 研究期和后20% 留出期。次日开盘策略在研究期累计收益36.30%，在留出期为-2.61%；同期留出期等权基准为-7.61%，因此累计主动收益仍为5.41%。这说明策略在下跌环境中相对抗跌，但尚未证明稳定的正绝对收益。




图 6.3: 完整样本、前80% 研究期与后20% 留出期比较。完整样本32.74% 不能替代独立样本外验证。

样本期划分与定义

本研究将全部数据按时间划分为研究期和独立留出期。研究期用于因子探索、模型拟合、参数选择和验证，其中验证期属于研究期的一部分。独立留出期在策略规则冻结前不参与任何研究决策，仅用于一次最终时间外推检验。“样本外”是对评估方式的描述，表示相关预测或收益来自未参与当前模型拟合和参数选择的数据，而不是与全样本、研究期、验证期和留出期并列的固定分区。全样本结果同时包含研究期和留出期，仅作为总体回测展示，不视为独立样本外证据。

表 6.2: 样本期统一定义

术语	定义	用途
全样本 (Full Sample)	报告覆盖的全部日期，包括研究期和独立留出期	展示总体净值、收益、回撤和交易成本
研究期 (Research Period)	用于因子探索、策略设计、模型拟合和参数选择的区间	确定因子、持仓数量、调仓频率、缓冲区和成本参数
验证期 (Validation Period)	研究期内部用于模型选择、超参数选择、阈值选择和早停的区间	比较候选方案并确定最终配置
留出期 (Holdout Period)	策略开发阶段完全隔离、待规则冻结后才使用的区间	进行一次最终的时间外推检验
样本外 (Out-of-Sample)	某次预测或回测使用了未参与当前模型拟合及参数选择的数据	描述Walk-forward 测试窗口或独立留出期结果

分阶段回测结果

为区分研究选择效应与时间外推能力，分别报告研究期、独立留出期及全样本的回测结果。

表 6.3: 分阶段回测结果

区间	数据用途	策略累计收益	等权基准累计收益	累计主动收益	结果性质
研究期 (前80%)	因子研究、参数选择和策略开发	36.30%	—	—	研究期结果
独立留出期 (后20%)	参数冻结后的最终检验	-2.61%	-7.61%	5.41%	独立样本外结果*
全样本	总体净值和风险展示	32.74%	—	—	全样本回测结果

* 只有在留出期未参与任何因子、参数或模型选择的情况下，才能称为独立样本外结果。主动收益应按照策略净值相对于基准净值计算，不能直接用两个累计收益率相减。

次日开盘策略在研究期累计收益为36.30%，在独立留出期的绝对收益为-2.61%。同期等权基准累计收益为-7.61%，策略在下跌环境中表现出一定相对抗跌能力，但尚未证明能够稳定获得正绝对收益。

7 多股票Walk-forward LSTM

7.1 样本与特征

分钟模型选取6 只股票和140 个交易日，以过去20 分钟预测下一分钟是否上涨。输入特征包括对数收益、分钟振幅、对数成交量、主动买卖不平衡和日内时间位置。标签定义为

$$y_{t+1} = \mathbb{I}(C_{t+1} > C_t). \quad (7.1)$$

每个样本只包含预测时点及以前的信息，避免把下一分钟数据放入输入窗口。

7.2 Expanding-window 验证

模型采用单层PyTorch LSTM，隐藏维度为16。验证使用3-fold expanding-window walk-forward：每折至少包含60 个训练日、20 个验证日和20 个测试日；标准化参数只用训练期估计，验证期负责选模，三个测试窗口互不重叠。合并后共有83,880 条样本外预测，上涨样本占31.09%。

表 7.1: 样本外分类结果

模型	Acc.	Bal.Acc.	Prec.	Recall	F1	ROC AUC	PR AUC
多数类	68.91%	50.00%	0.00%	0.00%	0.00%	0.5000	0.3109
逻辑回归	68.93%	51.23%	50.51%	4.40%	8.10%	0.6086	0.3993
LSTM	68.98%	52.28%	50.77%	8.10%	13.97%	0.6465	0.4276

7.3 准确率与解释

图 7.1 将合并样本外准确率与3-fold 测试准确率放在同一张图中。LSTM 的总体准确率为68.98%，但上涨样本仅占31.09%，因此一个始终预测下跌的多数类模型也能得到68.91% 的准确率。LSTM 相对多数类基线只提高了0.07 个百分点，不能把68.98% 直接解释为较强的方向预测能力。

相比之下，平衡准确率会分别计算上涨和下跌两类的召回率，再取平均。LSTM 的平衡准确率为52.28%，高于多数类的50.00% 和逻辑回归的51.23%，说明模型对少数类上涨样本提供了有限但为正的增量识别能力。3-fold测试准确率分别为69.22%、68.88% 和68.84%，时间窗口之间较稳定，但仍与多数类基线非常接近。




图 7.1: LSTM 准确率诊断。左图比较合并样本外Accuracy 与Balanced Accuracy; 右图比较3-fold 测试Accuracy。由于类别不平衡, 总体Accuracy 必须与多数类基线、平衡准确率和排序指标一起解释。

结合上涨召回率8.10%、ROC AUC 0.6465 和PR AUC 0.4276, 可以得到更完整的结论: LSTM 的概率排序优于逻辑回归, 但在0.5 阈值下仍漏掉了大量上涨分钟。模型目前适合被描述为具有一定样本外排序信息, 而不是已经形成高准确率或可直接交易的分钟策略。




图 7.2: 多数类、逻辑回归和LSTM 的样本外指标比较。LSTM 的排序指标高于逻辑回归。




图 7.3: LSTM 样本外混淆矩阵。True Positive为2,113, False Negative为23,969, 说明0.5 阈值下上涨召回率偏低。




图 7.4: 3-fold walk-forward 的逐折指标。逐折结果可用于判断表现是否集中在某一时间窗口。

LSTM 的ROC AUC、PR AUC 和F1 均高于逻辑回归, 说明序列结构提供了一定额外排序信息; 但总体准确率几乎等于多数类基线, 且上涨召回率仅8.10%。

8 结论

- 七个日频因子中，多数因子具有方向稳定的横截面信息；新增的单笔成交规模异常、价量压力和隔夜-日内背离没有复制参考材料中的因子。
- Historical IC 加权避免了同日未来收益泄漏；Top30、每5 日调仓和Top60 缓冲把日均单边换手降至约8.3%。
- 次日开盘口径完整样本成本后累计收益为32.74%，年化收益为29.51%，年化超额收益为25.70%，最大回撤为-11.27%。
- 最后20% 留出期的绝对收益仍为负，表明完整样本结果含有研究选择效应，需要继续用全新的时间区间进行walk-forward 检验。
- LSTM 的样本外排序指标高于逻辑回归，但0.5 阈值下上涨召回率较低。